

Route Choice

lab

2026-03-17



현재 진행중인 상황

✓ Route choice : Model MNL -> DeepL

- MNL: 유사도 방법론을 5-level(Spatial 50%)에서 3-level(Route 90%)로 개선하고, 2-Stage Grid Search로 최적 가중치를 도출하여 내생성(walk/IVT 왜곡)을 완화함
- fare 변수 제거(통합요금제 변별력 없음), GTX test split 보정까지 완료.
- 딥러닝 모델 선정 및 테스트 진행중(5개의 모델 중 DNN 모델이 가장 좋은 성능 및 모든 모델 다 MNL 보다 좋음)

✓ DTUMOS RAPTOR 알고리즘 고도화

- RAPTOR : JAVA -> RUST

항목	RUST Std	RUST MC	JAVA MC
초기화	10.1초	9.9초	54.1초
쿼리 평균	175ms	19ms	164ms
메모리	~1GB	~1GB	16GB
정확도(최단시간 기준)	9/10	9/10	기준

- 스마트카드를 이용한 GTFS 데이터 통행시간 보정 : 진행중 (모델 돌리는 과정 중)
- PM, TAXI 등 First/Last Mile 반영 : 진행 중(GBFS 데이터와 거리 비례를 활용한 방법)

✓ GTFS 기반 멀티모달 대중교통 시뮬레이션 프레임워크: 수도권 GTX 광역급행철도 평가 적용

- 초안 완성

Contents

- 01 연구 배경 - 멀티모달 시뮬레이션과 경로선택
- 02 선행연구 - 경로선택 모형, 유사도 지표, 스마트카드 매칭
- 03 연구방법론 - 유사도 지표
- 04 연구방법론 - 사용 모델 정의
- 05 연구방법론 - 3-level + Sequence Gate
- 06 연구방법론 - Sequence Gate: 우회 경로 필터링
- 07 가중치 최적화 (2-Stage Grid Search)
- 08 MNL 모형 결과 비교
- 09 향후 계획

1. 경로매칭 및 경로선택모형 추정

① 경로매칭 목적

- 대중교통 경로탐색 알고리즘은 OD별 후보경로를 제시하지만, 실제 이용자가 어떤 경로를 선택하는지는 알 수 없음
- 현실에서 이용자는 최단시간 경로만을 선택하지 않으며, 환승 부담·도보거리·익숙한 노선 등 개인의 선호에 따라 다양한 경로를 선택함
- 이러한 선택행태를 반영하기 위해 스마트카드 관측통행을 후보경로에 매칭하여 선택확률을 부여하는 과정이 필요하며, 이를 기반으로 경로선택모형(MNL)을 추정함

① 분석 범위

항목	값	비고
시간 범위	2025.02.17 ~ 02.23	7일 (평일 5 + 주말 2)
대중교통 경로탐색 OD	717,896 쌍	일 13회 이상 통행 OD
탐색 대안경로	2,720,686개	평균 3.8개/OD
스마트카드 통행	52,137,077건	7일 합산
모형	MNL (조건부 로짓)	-

2. 경로 유사도 측정 방법

 경로/궤적 유사도 측정 기법 비교

- 어떤 연구에서 어떤 지표를 사용했는가?

유사도 지표	수식/원리	사용 연구	적용 맥락	한계
Edit Distance (Levenshtein)	삽입/삭제/치환 최소 연산 횟수	Tiam-Lee & Henriques (2022)	정류장 시퀀스 차이 정량화	정규화 필요 계산 $O(nm)$
Hausdorff Distance	$\max(\min(d(a,b)))$ 최대-최소 점간 거리	Hassan et al.	경로 기하형상 공간적 유사도	이상치 민감 내생성 유발 가능
Fréchet Distance	단조 정렬 조건 하 최대 편차	Bai et al. (2023)	GPS 궤적 연속 경로 비교	계산 비용 높음 $O(nm)$
DTW (Dynamic Time Warping)	시간축 왜곡 허용 최적 정렬 거리	Yuan & Li (2021)	시계열 궤적 GPS 매칭	대중교통 정류장 데이터에 부적합

2. 연구의 차별성

① 선행연구 차이 분석

- 경로 중첩 보정 (PSL 계열): 링크/환승역 기반 중첩도 → 대안경로 생성 전제 (Choice Set 필요)
- 유사도 지표: Jaccard, LCS, Hausdorff 등 개별 지표 연구 → 복합 유사도의 최적 가중치 연구 부재
- 스마트카드 경로 식별: 단일 지표(시간/거리) 매칭 → 다차원 유사도 기반 확률적 매칭 미시도

② 본 연구의 차별점

구분	기존 선행연구	본 연구
경로 매칭 방식	단일 지표 (시간 비율 or 최단경로)	복합 유사도 (Mode + Route + Seq)
유사도 가중치	임의 설정 or 미사용	2-Stage Grid Search 최적화 (462개 시나리오)
공간적 유사도	Hausdorff 등 공간 지표 사용	제거 (내생성 유발 → MNL 계수 왜곡)
선택확률 부여	최단경로 = 선택 (이진)	유사도 기반 연속 확률 (softmax)
데이터 규모	수천~수만 통행	53만 OD, 160만 대안, 3,700만 통행
검증	ρ^2 또는 정확도 단일 지표	$\rho^2 + \text{FPR-1} + \text{FPR-3} + \text{수단분담률} + \beta\text{비율}$

제 3장 연구방법론

3. 유사도 지표

☑ 대중교통 경로탐색 알고리즘 경로 vs 스마트카드 통행 유사도 비교 방법

- 대중교통 경로탐색 알고리즘의 **경로에 선택 확률을 배정**해주고자 유사도 비교 과정 진행
- 대중교통 경로탐색 알고리즘이 제시한 후보 경로들 중에서 실제 **스마트카드 관측 통행**(OD/모드/환승 등)과 **가장 유사한 경로를 선택**
- 유사도 점수 기반으로 **매칭 성공/실패(임계값) 판정**

☑ 3단계 유사도 지표 (Level Metrics)

Level	비교 항목	대표 지표(예)
1	모드 조합	이용 수단 집합(버스/지하철/GTX) 일치 비율
2	정류장 시퀀스 (핵심)	경유 정류장 순서 일치 비율
3	노선 일치	이용 노선명 일치 비율

3.1 Mode · Route 유사도 산출

☑ Mode Similarity (mode_jaccard) — 교통수단 집합 비교

- SC 통행의 수단 집합과 OTP 대안의 수단 집합을 Jaccard Index로 비교
- $Jaccard = |SC \cap OTP| / |SC \cup OTP|$
- 수단 분류: bus, train(지하철/철도), gtx → 7개 카테고리 (bus_only, train_only, ...)

	SC 수단	OTP 수단	교집합	합집합
예시 1	{bus, train}	{bus, train}	2	2
예시 2	{bus}	{bus, train}	1	2
예시 3	{train}	{gtx}	0	2

☑ Route Similarity (route_jaccard) — 노선명 집합 비교 + GTFS 보정

- 노선명 정규화 후 Jaccard 비교
- 정규화 규칙: OTP "서울2호선" → "2호선" | SC "5531번(군포동행정복지센터방면)" → "5531"
- GTFS route_short_name 기반으로 OTP/SC 노선명을 통일하여 매칭 정확도 확보

	SC 노선 (정규화 후)	OTP 노선 (정규화 후)	Jaccard
예시 1	{2호선, 5531}	{2호선, 5531}	1.00
예시 2	{2호선, 5531}	{2호선, 5530}	$1/3 = 0.33$
예시 3	{7호선}	{2호선}	0.00

3.2 Sequence 유사도 산출 (GTFS 보정)

☑ 문제: OTP/SC 정류장 정보의 차이

- OTP: leg별 출발/도착 정류장만 기록 (중간 정류장 없음)
- SC(스마트카드): 승차/하차 정류장만 기록 (환승 시 중간 정류장 없음)
- 양쪽 모두 중간 경유 정류장이 누락 → 직접 비교 시 정보 손실

☑ 해결: GTFS 기반 정류장 시퀀스 확장 (expand_route)

- GTFS stop_times.txt에서 노선별 전체 정류장 순서를 조회
- OTP leg의 from→to 구간을 GTFS로 확장하여 중간 정류장 복원
- SC도 동일하게 노선+승하차 정류장으로 GTFS 확장
- 정류장명 fuzzy 매칭: OTP '군포1동행정복지센터.군포역' ↔ SC '군포역' → 부분일치 허용

단계	OTP (2호선 leg)	SC (2호선 승하차)
원본	from=강남, to=삼성 (2개)	승차=강남, 하차=삼성 (2개)
GTFS 확장	[강남, 역삼, 선릉, 삼성] (4개)	[강남, 역삼, 선릉, 삼성] (4개)
LCS 비교	$LCS = 4 / \max(4, 4) = 1.00$	완전 일치 ✓


$seq_lcs = LCS(OTP\text{확장}, SC\text{확장}) / \max(|OTP\text{확장}|, |SC\text{확장}|) \rightarrow$ 순서 보존하면서 공통 정류장 비율 측정

3.2 Sequence 유사도 산출 (GTFS 보정)


(a) LCS = 1.00: 완전 일치




(b) LCS = 0.75: 주요 노선 일치, 일부 상이



(c) LCS = 0.50: OD 동일, 중간 경로 상이



(d) LCS = 0.33: 수단 조합 상이



—●— AFC (관측 통행) - - - OTP (후보 경로)

3.3 Composite 산출 → choice_prob 변환

☑ Step 1: 개별 통행 매칭 — SC 1건 × OTP K개 대안

- $\text{Composite}(i) = w_{\text{mode}} \times \text{mode_jaccard} + w_{\text{route}} \times \text{route_jaccard} + w_{\text{seq}} \times \text{seq_lcs}$
- 각 SC 통행에 대해 K개 OTP 대안의 composite score 산출
- Gate: $\text{seq_lcs} < 0.3 \rightarrow$ 제외 (우회/왕복 필터)
- Threshold: $\text{composite} < 0.5 \rightarrow$ 제외 (저품질 매칭)
- 최고 점수 대안 $\rightarrow$ 해당 SC 통행의 매칭 경로 ($n_{\text{matched}} + 1$)

☑ Step 2: OD 집계 → choice_prob

- 동일 OD(출발-도착 정류장 쌍)의 SC 통행을 대안별로 집계
- $\text{choice_prob}(i) = n_{\text{matched}}(i) / n_{\text{total}}$ (대안 i에 매칭된 통행 비율)
- $\sum \text{choice_prob} = 1.0 \rightarrow$ MNL의 종속변수(y)로 사용

OD: 강남→종로 ($n_{\text{total}}=100$)	대안 1 (2호선→1호선)	대안 2 (3호선 직통)	대안 3 (버스 7016)
composite score	0.95	0.82	0.61
n_{matched}	60건	30건	10건
choice_prob	0.60	0.30	0.10

SC 37M trips $\rightarrow$ OD 530K $\times$ 대안 평균 3.7개 = 1.97M rows $\rightarrow$ 80/20 층화 Split $\rightarrow$ MNL β 추정

제 3장 연구방법론

4. 사용 모델 정의

✓ 사용 모델 정의

MNL (Multinomial Logit)

여러 경로 중 어떤 걸 선택할지 확률로 계산하는 모형"

- 예시:
출근길에 경로 A, B, C 세 가지가 있다고 하면, 각 경로에 "점수"를 매김
- 점수 = $\beta_1 \cdot \text{시간} + \beta_2 \cdot \text{환승} + \beta_3 \cdot \text{보행} + \dots$ 이 점수가 높은 경로일수록 선택 확률이 높아짐
- $P(A \text{ 선택}) = \frac{e^{\text{점수}_A}}{e^{\text{점수}_A} + e^{\text{점수}_B} + e^{\text{점수}_C}}$
→ β (가중치)를 데이터에서 찾아내는 것이 "모형 추정"

LL (Log-Likelihood)

모형이 실제 데이터를 얼마나 잘 설명하는지의 점수

- 예시:
실제로 사람들이 경로 A를 70% 선택했는데,
모형이 "A를 70% 선택할 것"이라고 예측하면 → LL 높음
모형이 "A를 10% 선택할 것"이라고 예측하면 → LL 낮음
- $LL(0)$: 아무것도 모를 때 (랜덤 찍기)
 $LL(\beta)$: 모형으로 예측했을 때
- $\rho^2 = 1 - LL(\beta)/LL(0)$
→ ρ^2 가 클수록 모형이 잘 설명하는 것

5. 방법론 (3-Level + Sequence Gate)

☑ Composite 산출식

- $S = 0.02 \times \text{Mode} + 0.90 \times \text{Route} + 0.08 \times \text{Sequence}$ | Gate: $\text{seq_lcs} \geq 0.3$

	기존 (5-Level)	개선 (3-Level)	변경 사유
Mode	0.10	0.02	Route에 이미 내포
Route	0.15	0.90 ★	경로 구분의 핵심
Sequence	0.15	0.08	경유지 감별 + 순서
Time	0.10	제거 (진단용)	변별력 부족
Spatial	0.50	제거 (진단용)	내생성 유발원
Threshold	0.6	0.5	OD 수 확보
Seq Gate	없음	≥ 0.3	우회 경로 필터링

핵심 변경 사항

- Route 90%: 한국 대중교통 특성상 노선명 = 정류장 집합
- Seq Gate ≥ 0.3 : 우회/왕복 1,064건 제거 (정밀도 100%)
- 진단 보존: Time, Spatial은 진단용으로 저장

6. 방법론 (Sequence Gate: 우회 경로 필터링)

☑ 문제 상황: 노선명이 같지만 방향/경유지가 다른 경우

예시: SC 강남→종로→강남(왕복) vs OTP 강남→종로(편도)

- $\text{route_jaccard} = 1.0$ (같은 노선!) → 매칭됨
- $\text{seq_lcs} = 0.5$ (다른 방향!) → Gate가 감지 ✓
- $\text{sim_sequence} \geq 0.3$ 이상만 유효 매칭으로 인정

☑ Sequence Gate Sweep 결과

Seq Gate	ODs	test p^2	test FPR
0.0 (없음)	460,902	0.5205	77.5%
0.1	454,514	0.5203	77.5%
0.2	444,132	0.5197	77.4%
0.3 ★	436,841	0.5208	77.5%
0.4	432,473	0.5233	77.7%
0.5	425,921	0.5251	77.9%

결론

- 전 구간 p^2/FPR 거의 동일 ($\text{spread} < 0.005$)
- 0.3 선택: 필터링 목적 달성 + OD 손실 0.2%

7. 가중치 최적화 (2-Stage Grid Search)

① 2단계 Grid Search

- mode = 1 - route - sequence (제약 조건), 각 시나리오별 MNL 추정

단계	범위	Step	시나리오 수	결과
Coarse	route [0,1] × seq [0,1]	0.05	231	ρ^2 0.459~0.506
Fine	route [0.80,1.00] × seq [0.00,0.20]	0.01	231	ρ^2 0.496~0.522

① Fine Grid 결과 분석

- 클러스터 A: route $\geq 0.96 \rightarrow$ 최고 ρ^2 0.4970이나 seq 비중 부족 (방어 불가)
- 클러스터 B: route 0.84~0.91 $\rightarrow \rho^2$ 유사 (0.005 차이), 균형 잡힌 가중치

① 최종 선택

Route	Seq	Mode	ρ^2	FPR	ODs
0.90	0.08	0.02	0.520	77.5%	437K

8. MNL β 계수 추정 결과☑ β 계수 (3-level, route=0.90, seq=0.08, mode=0.02)

• Train: 424,551 ODs / 1,578,859 rows | Test: 106,138 ODs / 394,494 rows

Feature	β	Std.Err	t-stat
IVT (min)	-0.00704	0.000106	-66.2
Wait (min)	0.000 ★	—	—
Access walk (min)	-0.8349	0.000491	-1699
Egress walk (min)	-0.5122	0.000326	-1570
Transfer walk (min)	-0.0163	0.000506	-32.1
Total dist (km)	-0.0433	0.000348	-125
Transfers	-3.6575	0.001874	-1952
Has bus (ASC)	-2.2278	0.001815	-1228
Has train (ASC)	+2.9852	0.002749	+1086
Has GTX (ASC)	+0.1060	0.025368	+4.18
Access walk (min)	-0.8349	0.000491	-1699

수단분담률 재현

Category	SC 실측 (37M)	Train y (29.6M)	MNL 예측 (7.4M)
train_only	48.84%	48.69%	49.39%
bus_only	42.91%	43.01%	42.54%
bus+train	8.15%	8.18%	7.95%
train+gtx	0.072%	0.072%	0.091%
gtx_only	0.028%	0.036%	0.019%
bus+trn+gtx	0.006%	0.006%	0.006%
bus+gtx	0.002%	0.002%	0.002%

★ bound: 비음 제약($\beta \leq 0$) 하에서 0에 고정. fare는 통합요금제 구조, wait는 다른 변수에 흡수.

8. MNL 모형 결과 비교

④ 이전 vs 현재 MNL 성능

- 유사도 방법론 변경에 따른 모형 성능 비교

지표	이전	현재	변화	DNN
Train p^2	0.4746	0.4925	+0.018 ↑	-
Test p^2	0.4724	0.4870	+0.015 ↑	0.5369
FPR-1 (1순위)	70.3%	70.9%	+0.6%p ↑	73.15%
FPR-3 (TOP-3)	96.2%	96.1%	-0.1%p	97.26%
ODs (train)	478,345	424,549	-53,794	424,549

④ β 계수 비율 개선 (walk / IVT)

- access_walk / IVT: 165배 → 119배 (개선)
- egress_walk / IVT: 155배 → 73배 (크게 개선)
- transfer_walk / IVT: 25배 → 2.3배 (거의 해소)

제 3장 연구방법론

8. MNL 모형 결과 비교

☑ 전체 모델 β 값

β 값 비교 (전체 6개 모델, fare 포함)

피처	MNL	TasteNet	ResLogit	L-MNL	DNN*	ASU-DNN*
IVT (min)	-0.0070	-0.0049	-0.0111	-0.0142	-0.0012	+0.0002
Wait (min)	0.0	+0.0243	+0.0423	-0.0194	+0.0002	+0.0023
Access walk	-0.8347	-0.7332	-1.0461	-0.7372	-0.0699	-0.0420
Egress walk	-0.5121	-0.3151	-0.3572	-0.3092	-0.0495	-0.0135
Transfer walk	-0.0162	-0.0120	+0.1348	+0.0916	+0.0052	-0.0066
Distance (km)	-0.0433	-0.0674	-0.0110	-0.0031	-0.0001	+0.0007
Transfers	-3.6571	-3.3782	-2.9907	-1.7916	+0.0911	-0.0248
Fare	0.0	+0.0009	+0.0004	+0.0002	+0.0002	-0.0001
Has bus	-2.2277	-2.8631	-2.0015	-2.1601	-0.3829	-0.0719
Has train	+2.9848	+3.5958	+1.7574	+0.2797	+0.2238	+0.0734
Has GTX	+0.1064	-4.4206	-1.4057	-2.0540	+0.1387	-0.0887

*DNN/ASU-DNN은 gradient pseudo- β (크기가 작은 건 softmax 확률의 gradient라서 정상)

주목할 점:

- Fare: 모든 DL 모델에서 $\approx 0 \rightarrow$ MNL과 동일하게 fare는 무의미
- Has GTX: TasteNet(-4.42), ResLogit(-1.41), L-MNL(-2.05) 모두 강한 음수 - MNL(+0.1)과 반대
- Wait time: TasteNet/ResLogit은 양수(+), L-MNL은 음수(-) - 모델 간 불일치

9. 이슈 분석

✓ fare $\beta = 0 \rightarrow$ 제거

- 60.8% OD: 대안 간 요금 차이 = 0원 (수도권 통합요금제)
- 81.7% OD: 요금 차이 $\leq$ 50원 $\rightarrow$ 변별력 없음

✓ wait_time $\beta = 0 \rightarrow$ 유지 (제거시 모형 안 좋아짐)

- 분산 있음 (87.9% OD에서 $\text{std} > 0$), 부호 방향 정상
- 다른 변수에 설명력 흡수 $\rightarrow$ 데이터 개선 시 활성화 가능

✓ walk 과대 / IVT 과소

- 가중치 변경으로 상당히 완화되었으나 access/egress 여전히 과대
- MNL의 구조적 한계 (선형 효용) $\rightarrow$ 딥러닝 기반 모형으로 개선 예정

✓ GTX 과추정 $\rightarrow$ 크게 개선

- has_gtx ASC: +0.469 $\rightarrow$ +0.106 (78% 감소)
- GTX 포함 경로 1.00%, 평균 choice_prob 0.030

9. 향후 연구 계획

④ 딥러닝 기반 경로선택 모형

- MNL의 선형 효용 한계 극복 → 비선형 효용 + 비관측 이질성 반영
- 날씨, 인구통계 등 맥락 변수 통합 가능

감사합니다

Thank you

김민수

가천대학교 스마트시티융합학과 박사과정
alstn3316@gachon.ac.kr